

Arquitetura Santa Cecília

Sistemas escaláveis, seguros e preparados para o mundo real

8 de outubro de 2026 · Conteúdo conforme os 25 slides do PPT/PDF

Repositório público

<https://github.com/DevKaue/arquitetura-santa-cecilia>

Referência: main. Arquitetura completa e importação complementar por URL.

Como usar este guia

1. Resumo executivo: alinhar as decisões e os slides com a chefia.
2. Roteiro: seguir a construção e a operação conforme a palestra.
3. Cartão do apresentador: consultar a sequência e os números.
4. Perguntas e respostas: conduzir a discussão por tema.
5. Opções de condução: 10/5 min como apoio, sem limitar o principal.
6. Correspondência: conferir os 25 slides e os complementos.

Principal: v19 · 23 blocos · 40 relações. Evolução dos slides no histórico; versões anteriores e 3 Labs mantidos.

Resumo executivo para revisão

Referência: os 25 slides do PPT e as 25 páginas do PDF “Como projetar sistemas escaláveis, seguros e preparados para o mundo real”, fornecidos para a palestra de 8 de outubro de 2026. **Principal no Build Arch Desktop: v19, 23 blocos, 40 relações.** O conteúdo acompanha a palestra inteira; a duração da fala fica a critério dos apresentadores.

O caso e as perguntas de negócio

Loja disponível em vários países, com clientes em vários continentes/fusos e milhões de visitas por dia. Black Friday pode multiplicar o tráfego por **10x**; o perfil é **95% leitura / 5% escrita**. Erros de estoque, pedido duplicado ou cobrança errada tornam checkout/pagamento críticos (slides 3-4).

Antes das peças: quantos usuários e de onde, qual pico, o que não pode cair e o que pode demorar a atualizar. Exibir estoque com atraso pode ser aceitável; decidir a compra exige o dado autoritativo.

As oito peças explicadas na palestra

Peça	Função no principal	Referência
Borda: cliente, DNS e CDN	Resolver destino e aproximar conteúdo estático; WAF/anti-DDoS na referência final	13, 19
Load Balancer / entrada	Distribuir para instâncias saudáveis; TLS, limites e controle de acesso	10, 14, 19, 21
Aplicação stateless	Escalar cópias sem sessão local; autenticação e autorização antes do domínio	8, 15, 19
Cache	Absorver consultas repetidas; proteger dados sensíveis	9, 16
Writer e réplicas	Separar escrita autoritativa e leitura eventual	11, 17
Fila e workers	Retirar trabalho posterior da resposta; escalar por fila	18-19
Observabilidade	Métricas, logs e tracing para identificar saturação e falhas	18-19, 22-23
Multi-região	Proximidade do cliente e continuidade quando uma região falha	18

O desenho de referência e o mundo real

A v19 explicita as camadas do slide 19: **borda, entrada, orquestração, dados, observabilidade e entrega**. WAF e CDN são blocos separados. As duas réplicas continuam separadas. Autenticação, Kubernetes ou equivalente, autoscaler, dashboards, logs e análise estática têm função visível.

O mapa também inclui tracing e região secundária do slide 18. **Sala de espera** representa a política opcional do slide 21, distinta da fila de trabalho. Timeout/retry/circuit breaker, modo degradado, teto de escala, alarme, canary e rollback estão descritos nas peças responsáveis. Nenhum deles depende de acrescentar uma caixa fictícia para cada conceito.

Exemplos numéricos preservados das fontes

Exemplo da palestra	Significado
95% / 5%; pico 10x	Perfil de leitura/escrita e crescimento do tráfego
90% de conteúdo estável	Justificativa da CDN no slide 13; não é taxa de cache HIT medida
50 mil mensagens por hora; 3 para 20 workers	Exemplo assíncrono do slide 18
Latência aumenta 3 min antes do primeiro erro	Exemplo de observação do slide 18; antecipação não garantida
40 ms local / 220 ms cruzando o Atlântico	Exemplo de proximidade regional do slide 18
99%	Aproximadamente 3,65 dias fora do ar/ano, no slide 7
99,9%	Aproximadamente 8,8 horas fora do ar/ano
99,99%	Aproximadamente 52 minutos fora do ar/ano
99,999%	Aproximadamente 5 minutos fora do ar/ano

Os slides não definem 2.000 req/min, TTL de 60 s, cache HIT de 90% ou metas numéricas RPO/RTO. Esses parâmetros surgiram no aprofundamento anterior e nos Labs; não são apresentados como dados do material original.

Evolução disponível no histórico

Revisão	O que mostrar
v12	Slide 5: servidor e banco únicos
v13	Slide 13: cliente, DNS e CDN
v14	Slide 14: entrada e TLS
v15	Slide 15: App 1, App 2 e App 3
v16	Slide 16: cache
v17	Slide 17: writer e duas réplicas
v18	Slide 18: fila, observabilidade e multi-região
v19	Referência completa e operação dos slides 19-25

As versões v1-v10 e o estado do Desktop anterior à reorganização (v11) foram preservados. A v9 mantém outbox, relay, DLQ e pagamento externo como aprofundamento. Os três Labs e o schema de oito tabelas continuam disponíveis.

Demonstração, custos e fechamento

Slides 22-23: elevar a carga, observar latência, saturação e qual peça limita o sistema. Os Labs com os mesmos controles mostram que aumentar APIs não resolve um banco compartilhado limitante. As saídas dos motores são estimativas de modelo; P95 de produção exige instrumentação e teste reais.

Slide 24: comparar **compute, storage, egress e CDN**, além do esforço de operação, em AWS, GCP, Azure e Alibaba Cloud. As marcas são alternativas; não são serviços simultâneos nem preços fixos. Campos de custo do Build Arch são didáticos.

Slide 25: arquitetura evolui com o problema, segurança acompanha cada peça e operação precisa de medição e caminho de volta. A correspondência dos 25 slides permite conferir a cobertura com a chefia. O roteiro curto opcional mantém as alternativas de 10/5 min, sem determinar o conteúdo do principal.

Roteiro da demonstração conforme a palestra

O roteiro segue a ordem e o conteúdo do PPT/PDF. **A duração fica a critério de vocês.** Abrir o principal em **Trabalho atual - v19**, conferir **Salvo agora** e enquadrar o canvas. As conexões de DNS, orquestração, telemetria e entrega têm função de controle/operação; não são todas etapas de uma compra.

1. O problema antes do desenho - slides 3-5

Mostrar: Usuários globais; depois a revisão **v12**, correspondente ao slide 5.

Explicar: clientes em vários fusos, milhões de visitas/dia, pico 10x e perfil 95/5. Listagem tolera atraso; checkout/pagamento têm impacto financeiro. Perguntas de negócio definem localização, capacidade e criticidade.

Fala: “Com tudo em um servidor e um banco, consulta e compra disputam os mesmos recursos. Cada peça que vem depois responde a uma necessidade deste caso.”

2. Vocabulário que orienta as decisões - slides 6-12

Relacionar latência (tempo de resposta) e throughput (quantidade por unidade de tempo). Mais instâncias aumentam capacidade quando a dependência compartilhada comporta a demanda. Disponibilidade tem custo: o slide 7 compara os quatro níveis de nozes, sem escolher um SLO para o caso.

Retomar cache, balanceamento e consistência. Catálogo pode aceitar propagação; a compra usa a fonte da verdade. No inspetor de catálogo/checkout, mostrar **timeout, retry limitado e circuit breaker** como comportamento das dependências.

3. Cliente, DNS e CDN - slide 13, v13

Ação: abrir a revisão v13. Apontar a consulta DNS e o caminho HTTPS para CDN.

Fala: “DNS resolve o domínio. A CDN entrega imagens, CSS e JavaScript perto do usuário. A requisição HTTPS não passa pelo DNS como por um proxy.”

O slide usa **90% de conteúdo estável** para justificar a borda. Não converter esse número em cache HIT medido. Clientes distantes ganham proximidade sem sobrecarregar o backend.

4. Load Balancer - slide 14, v14

Mostrar: entrada adicionada depois da borda; apontar distribuição e exclusão de instâncias sem resposta.

Fala: “O dinâmico vai para uma instância saudável. TLS termina na entrada e uma nova sessão protege o trecho até a aplicação.”

Na referência final, esta peça incorpora gateway e rate limiting. Banco, cache e broker ficam fora do acesso público.

5. Aplicação em múltiplas instâncias - slide 15, v15

Mostrar: App 1, App 2 e App 3. Cada uma representa uma cópia descartável sem sessão local de usuário.

Fala: “Qualquer instância pode atender uma requisição. Para a compra, autenticação e autorização precisam ocorrer antes da regra de negócio.”

Na v19, o slide 19 refina as responsabilidades em API de catálogo, API de checkout e serviço de notificações. Catálogo/checkout continuam com três instâncias no exemplo; não equivalem a apenas uma cópia de cada serviço.

6. Cache - slide 16, v16

Mostrar: cache adicionado às aplicações. No inspetor, explicar HIT/MISS e dados permitidos.

Fala: “Perguntas repetidas sobre catálogo são atendidas em memória. Pagamento e documentos não entram nesse cache; informação pessoal exige TTL curto.”

TTL/invalidação e limite de fallback são políticas de implementação. O slide não determina segundos de TTL nem uma taxa HIT.

7. Banco de escrita e réplicas - slide 17, v17

Mostrar: writer e **duas réplicas separadas**. Explicar que cada consulta escolhe um destino de leitura, enquanto checkout escreve na fonte da verdade.

Fala: “Leitura e escrita crescem conforme necessidades diferentes. A tela pode mostrar um valor atrasado; a decisão de vender precisa validar estoque no banco autoritativo.”

Segurança do slide: criptografia em repouso e usuários de menor privilégio. Um standby de HA não é um segundo writer. O schema de oito tabelas fica como aprofundamento do exemplo.

8. Assíncrono, observabilidade e multi-região - slide 18, v18

Fila e worker: e-mail e baixa operacional de estoque saem da resposta imediata. A decisão de reserva permanece no checkout, conforme slides 4/11/17. O exemplo da palestra é **50 mil mensagens/h**, com workers de **3 para 20**, por tamanho da fila. Mensagens levam só o necessário, sem segredos.

Observabilidade: mostrar métricas, logs e tracing; correlacionar saturação e latência. Logs mascaram dados sensíveis. O aviso **3 min antes do primeiro erro** é um exemplo do slide, sem garantia de antecipação.

Multi-região: mostrar DNS geográfico, região secundária e réplica próxima. O caso compara **40 ms local** com **220 ms transatlântico**. Considerar residência de dados. Falha de região exige capacidade de assumir, dados disponíveis e mudança de roteamento; o slide não fixa RPO/RTO.

9. Arquitetura de referência completa - slide 19, v19

Ação: voltar a **Trabalho atual - v19**. Percorrer as camadas visíveis: borda; entrada/identidade; apps/orquestração/autoscaler; dados; observabilidade; entrega.

Fala: “O provedor e os nomes das ferramentas podem mudar. A função de cada camada é a mesma do desenho dos slides.”

Explicar WAF/anti-DDoS, OAuth2/OIDC, containers em Kubernetes ou equivalente, autoscaling por CPU/fila e análise estática a cada PR. Redis/Memcached, SQL e SQS/RabbitMQ/Pub/Sub são alternativas, não escolhas simultâneas obrigatórias.

10. Lançar e sobreviver ao pico - slides 20-21

Mostrar: CI/CD/rollback, métricas, autoscaler e sala de espera.

Canary recebe uma fração do tráfego ou uma região; se as métricas piorarem, voltar à versão anterior. Em pico extremo, combinar rate limiting, controle de admissão, modo degradado e teto com alarme. Desligar recomendações/avaliações preserva o essencial. **Sala de espera é acesso; fila assíncrona é trabalho.**

11. Carga e gargalo - slides 22-23

Ação: mostrar as peças do principal e usar os Labs para a comparação controlada. Os motores do Build Arch estimam resultados; o mapa completo inclui planos de controle/replicação que não devem ser interpretados como todos os saltos HTTP.

Temporal: **2.000 req/min, Pico, 4x, 10 min virtuais, Nenhuma falha.**

Saída do modelo	Lab 01	Lab 02	Lab 03
Instâncias de API	1	6	6
Capacidade de banco cadastrada, req/min	3.000	3.000	20.000
Latência estimada, ms	895	895	48
Erro estimado	68%	68%	0,05%

Fala: "Mais APIs continuam chegando ao mesmo banco. A peça que limita o sistema orienta o investimento."

Carga ao vivo 10x, como exercício complementar: **2.000 usuários × 10 ações/min, 30 s virtuais**. Gera 10.000 requisições; Labs 01/02 deixam aproximadamente 2.650 pendentes no limite de drenagem; Lab 03 termina sem pendências. Esses parâmetros são do nosso exercício, não valores fixados no PPT. Não apresentar a latência temporal como P95 medido.

12. Custos e encerramento - slides 24-25

Apontar onde surgem **compute, storage, egress e CDN**. Comparar serviço gerenciado com operação própria, incluindo esforço da equipe. A palestra cita AWS, GCP, Azure e Alibaba Cloud; o mapa permanece independente de provedor. Nenhum preço fixo é estabelecido.

Fala: "A arquitetura evolui com o problema. Segurança acompanha cada peça. Em produção, medir e ter caminho de volta fazem parte do desenho."

Importação do GitHub como recurso complementar

Analisar projeto > GitHub público. URL: <https://github.com/DevKaue/arquitetura-santa-cecilia>, referência **main**. Revisar evidências; o Compose de nove serviços gera 23 blocos/22 relações no motor verificado. A inferência inclui imagens, redes e abstrações; não equivale a 23 microsserviços. É um recurso adicional da nossa demonstração, não uma etapa descrita nos slides.

Se a rede falhar, usar o principal já salvo e os relatórios locais. O roteiro de 10/5 min continua como opção de condução, sem reduzir o conteúdo preparado.

Cartão do apresentador

Principal: v19 · 23 blocos · 40 relações. Enquadrar o canvas e conferir **Salvo agora**. A sequência segue os slides; ajustar a duração durante o ensaio conjunto.

Slides	O que apontar	Frase para ligar ao conteúdo
3-5	Usuários / v12 inicial	"O problema e o pico definem as peças."
6-12	Métricas, apps e dependências	"Tempo de resposta e capacidade são medidas diferentes."
13 / v13	Cliente, DNS, CDN	"Resolver o domínio e entregar perto do usuário."
14 / v14	Load Balancer	"Distribuir para instâncias saudáveis, com TLS."
15 / v15	App 1, 2 e 3	"Qualquer instância pode atender; autorização vem antes do domínio."
16 / v16	Cache	"Consulta repetida não precisa chegar ao banco."
17 / v17	Writer / duas réplicas	"Catálogo aceita atraso; compra usa a fonte da verdade."
18 / v18	Fila, telemetria, região	"Trabalho posterior, visibilidade e proximidade."
19 / v19	Todas as camadas	"A tecnologia muda; a função permanece."
20-21	Canary, teto, espera	"Reduzir o alcance do erro e controlar a entrada."
22-23	Labs 01/02/03	"Escalar a peça errada mantém o gargalo."
24-25	Custos / histórico	"Medir, escolher e manter caminho de volta."

Números do material original

95/5; pico 10x; 90% conteúdo estável; 50 mil mensagens/h; workers 3 > 20; aviso ilustrativo 3 min; leitura local 40 ms versus 220 ms. Não confundir 90% conteúdo estável com HIT do cache, nem antecipação ilustrativa com garantia.

Controles dos Labs

Temporal: **2.000 req/min · Pico · 4x · 10 min virtuais · Nenhuma falha.** Labs 01/02: **895 ms / 68%**; Lab 03: **48 ms / 0,05%**. São saídas do modelo.

Carga ao vivo: **2.000 usuários · 10 ações/min · 30 s virtuais.** 10.000 geradas; Labs 01/02 deixam ~2.650 pendentes; Lab 03 drena tudo. Os slides não fixam esses controles.

URL complementar pronta

<https://github.com/DevKaue/arquitetura-santa-cecilia>, referência **main**. **Analisar projeto > GitHub público.** Conferir evidências; inferência verificada: **23 blocos/22 relações**, distinta do principal manual **23/40**.

Apoio e contingência

Versões anteriores e três Labs mantidos. Outbox/DLQ/schema estão no aprofundamento; não fazem parte da figura original do slide 19. Se faltar rede, usar o projeto salvo. Opções de 10 e 5 minutos disponíveis sem limitar o principal.

Perguntas e respostas para discussão

Usar as respostas breves durante as perguntas e o aprofundamento conforme o interesse da plateia. A numeração segue os temas discutidos na palestra; questões de implementação complementam os slides e estão identificadas como apoio.

A. Escolha e evolução da arquitetura

1. É necessário começar com microsserviços?

Resposta breve: não. Um monólito modular pode atender a fase inicial com menos custo operacional.

Aprofundamento: separar implantação faz sentido quando volume, autonomia da equipe, frequência de mudança ou isolamento de falhas justificam observabilidade, comunicação distribuída e operação adicionais. O mapa ensina responsabilidades; não impõe um estilo único.

2. Como decidir o que escalar?

Resposta breve: medir a dependência limitante antes de aumentar instâncias.

Aprofundamento: olhar saturação, filas, latência medida, erros, queries, índices, pool de conexões e concorrência. No Lab 02, seis APIs continuam chegando ao mesmo banco. O Lab 03 altera a capacidade cadastrada no limitador; a intervenção real precisa de medição.

3. Qual o custo dessa arquitetura?

Resposta breve: o painel apresenta valores didáticos; um orçamento real depende do uso e do provedor.

Aprofundamento: região, tráfego de saída, requests, processamento, armazenamento, observabilidade, suporte e operação precisam entrar na conta. Autoscaling exige teto e proteção das dependências compartilhadas.

B. Dados, cache e compra

4. O que significa o perfil 95/5?

Resposta breve: é a hipótese de negócio: 95% das chamadas leem e 5% escrevem.

Aprofundamento: no pico ilustrativo de 20.000 req/min dos Labs, seriam 19.000 leituras e 1.000 escritas. O slide 13 fala em 90% de conteúdo estável. Um HIT de 90% é uma hipótese adicional do exercício e deixa 1.900 leituras chegando ao banco. O motor de ramificações não aplica automaticamente esses percentuais.

5. Como impedir que dois clientes comprem a última unidade?

Resposta breve: decidir a reserva no writer com atualização condicional dentro da transação.

Aprofundamento: atualizar somente se houver estoque suficiente; fazer rollback de todos os itens se um falhar. Usar ordem estável para itens e tratar deadlock/retry com idempotência. Um teste concorrente deve provar que o saldo não fica negativo.

6. Cache ou réplica podem decidir a reserva?

Resposta breve: a tela pode aceitar atraso; a reserva usa o dado autoritativo.

Aprofundamento: TTL e replicação podem exibir estado antigo. A API de compra precisa conferir disponibilidade, preço e autorização no domínio apropriado. Falha do cache exige fallback limitado para não provocar avalanche no banco.

7. Standby aumenta a capacidade de escrita?

Resposta breve: não. O modelo mantém um writer e um standby para alta disponibilidade.

Aprofundamento: réplicas A/B atendem leituras do catálogo com atraso possível. HA, distribuição de leitura e capacidade de escrita são decisões distintas. A promoção deve impedir que o writer antigo continue aceitando escrita.

C. Resiliência e processamento assíncrono

Outbox e DLQ são aprofundamento de implementação do nosso exemplo; o desenho original apresenta fila e worker.

8. Retry sempre melhora a disponibilidade?

Resposta breve: retry sem limite pode aumentar a sobrecarga e repetir efeitos.

Aprofundamento: timeout, backoff com jitter, orçamento finito e idempotência são necessários. Em pagamento, timeout significa resultado desconhecido: consultar estado ou reconciliar antes de compensar a reserva.

9. Outbox garante exatamente uma entrega?

Resposta breve: não. Ela grava pedido e intenção de publicar na mesma transação local.

Aprofundamento: o relay pode publicar, receber confirmação e cair antes de marcar o evento. A repetição exige deduplicação por evento/consumidor. O evento de compra confirmada nasce após reconciliação do pagamento; criar pedido não autoriza enviar confirmação de compra.

10. Como evitar e-mail duplicado?

Resposta breve: o efeito externo também precisa de uma política de idempotência.

Aprofundamento: gravar `processed_events` não torna atômica a chamada ao serviço de e-mail. Exigir idempotência do provedor ou documentar a tolerância a duplicata e a reconciliação. ACK deve acompanhar a política de efeito durável.

11. Para que serve a DLQ?

Resposta breve: retirar mensagens que esgotaram tentativas e permitir investigação e reprocessamento controlado.

Aprofundamento: monitorar idade/volume, definir responsável e retenção, corrigir a causa e repetir com deduplicação. DLQ sem processo operacional vira acúmulo de problema.

D. Segurança, operação e recuperação

12. WAF e token válido bastam para segurança?

Resposta breve: não. A aplicação também precisa validar entrada e autorizar cada recurso.

Aprofundamento: conferir o dono do pedido, menor privilégio no banco e nos serviços, rede privada para dados/broker, segredos por ambiente e logs sem tokens/cartão. WAF atua na borda; não conhece todas as regras do domínio.

13. Qual a disponibilidade real? E a recuperação de região?

Resposta breve: disponibilidade exige medição; RPO/RTO exigem teste de desastre.

Aprofundamento: definir SLI, período de observação e SLO. O slide 18 não fixa metas RPO/RTO. Os valores 5/30 min das versões anteriores eram hipóteses extras; definir metas exige ensaio de restore, promoção, fencing e roteamento. CDN mundial não torna o writer active-active nem substitui backup.

E. Build Arch e repositório

14. Por que a arquitetura inferida é diferente do desenho final?

Resposta breve: os manifests revelam recursos e dependências; o desenho final incorpora decisões de negócio e operação.

Aprofundamento: a inferência inclui redes, volume, imagens e abstrações com possíveis sobreposições. Revisar evidências e separar inicialização de chamada real. Capacidade, segurança, consistência e fluxo de pagamento não são comprovados por `depends_on`.

15. A nota do diagnóstico e os números da simulação garantem o sistema?

Resposta breve: são indicadores do modelo, úteis para discutir hipóteses.

Aprofundamento: o diagnóstico examina blocos; a redundância A/B depende do roteamento saudável do conjunto. O simulador temporal e a carga ao vivo usam motores distintos. Um sistema real precisa de benchmark, teste concorrente, teste de falhas e observação.

16. O repositório implementa uma plataforma de compras completa?

Resposta breve: publica o exemplo arquitetural, manifests e endpoints demonstrativos.

Aprofundamento: o catálogo é sintético, checkout retorna 501 e relay/worker não processam eventos. O schema explicita invariantes; o comportamento de domínio está descrito nas notas técnicas. O objetivo ao importar do GitHub é revisar evidências de arquitetura.

F. Correspondência com os slides

17. Onde aparecem as peças da palestra?

Resposta breve: todas as funções da referência do slide 19 estão na v19, com réplicas, tracing e região retomando os slides 17-18.

Aprofundamento: v12 mostra a caixa única do slide 5; v13-v18 acompanham a construção original. Blocos incluem motivo, segurança e referência; matriz dos 25 slides registra a cobertura. Versões anteriores continuam no histórico.

18. Circuit breaker faz o quê?

Resposta breve: interrompe temporariamente chamadas a uma dependência que falha, contendo o problema.

Aprofundamento: slide 12 combina timeout, retry e circuit breaker. Tentativas precisam de limite e idempotência quando repetem efeitos. A política pertence ao código/proxy da dependência; o desenho não inventa um serviço separado para ela.

19. Sala de espera é a mesma fila do worker?

Resposta breve: são funções distintas: a primeira controla entrada; a segunda guarda trabalho posterior.

Aprofundamento: slide 21 protege o acesso em pico extremo. Slide 18 desacopla e-mail/baixa operacional. Nenhuma substitui planejamento de capacidade.

20. Baixa de estoque pode esperar?

Resposta breve: a operação posterior pode esperar; a decisão de vender exige reserva autoritativa.

Aprofundamento: slide 18 trata a baixa no processamento assíncrono, enquanto slides 4/11/17 exigem correção no estoque da compra. Reservar no checkout e consolidar a baixa depois mantém as duas ideias. A implementação deve evitar liberar ou vender a mesma unidade duas vezes.

21. Por que comparar gerenciado e operação própria?

Resposta breve: custo inclui a equipe que opera o sistema, além da infraestrutura.

Aprofundamento: slide 24 compara compute, storage, egress e CDN. AWS, GCP, Azure e Alibaba Cloud são alternativas com pacotes próprios; a palestra evita preços fixos. Disponibilidade, suporte, observabilidade e esforço operacional também influenciam a decisão.

Opções de condução em 10 ou 5 minutos

Estas opções preservam o pedido anterior como recurso de ensaio. **O principal v19 contém o conteúdo completo da palestra.** O apresentador escolhe a duração; o mapa não foi reduzido para caber neste cartão.

Opção de 10 minutos

Tempo	Mostrar
0-1 min	Caso: público global, 95/5, pico 10x
1-4 min	Borda/entrada; catálogo e compra; fila/worker
4-6 min	Observabilidade, multi-região, canary e proteção de pico
6-9 min	Comparação dos Labs 01/02/03 ou resultados já conferidos
9-10 min	Custo das peças e fechamento dos slides 24-25

Se quiser mostrar importação do GitHub, usar parte do bloco 4-6 min e apontar uma evidência. Trata-se de recurso complementar; a ferramenta e a rede precisam estar ensaiadas.

Backup de 5 minutos

Tempo	Mostrar
0-1 min	Caso e visão geral
1-3 min	Leitura eventual, compra autoritativa e pós-compra
3-4:30 min	Observabilidade, proteção de pico e uma comparação pronta dos Labs
4:30-5 min	Custo, evolução e caminho de volta

Usar resultados prontos e o mapa salvo. Histórico e importação podem ficar para perguntas. Se houver falha de rede, seguir pelo conteúdo local. Nenhuma das opções exige construir componentes ao vivo.

Correspondência entre a palestra e o Build Arch

Os 25 slides do PPT e as 25 páginas do PDF foram comparados. A extração mostrou diferenças de quebra de palavras e ligaduras; os temas, exemplos e a sequência coincidem. As fontes originais permanecem intactas, fora do repositório público. Hashes e cobertura por slide estão no registro de alinhamento.

O principal é **v19**, com **23 blocos e 40 relações**. A correspondência abaixo identifica funções do material original e complementos de implementação. Não significa que os slides comprovam a infraestrutura ou os resultados de produção.

Slide / página	Conteúdo original	Representação no Build Arch
1	Tema e estudo de caso	Título e 8 peças preservados como tema; nome do projeto continua Arquitetura Santa Cecília.
2	Roteiro da palestra	Problema, conceitos, construção, demonstração e custos aparecem no roteiro de apoio.
3	Caso global, pico 10x e perfil 95/5	Milhões de visitas/dia é contexto; nenhum req/min fixado pelo slide.
4	Perguntas de negócio	Origem, pico, criticidade e atraso tolerado descritos antes das peças.
5	Tudo numa caixa só	v12. Estado inicial sem redundância preservado em revisão própria.
6	Latência e throughput	Unidades e significado separados; números do modelo não são medição real.
7	Disponibilidade e custo	99%, 99,9%, 99,99%, 99,999% permanecem no material; nenhuma meta extra imposta.
8	Escala vertical e horizontal	v15. App 1/2/3 na evolução; grupos com 3 instâncias no principal.
9	Cache	v16. Absorção de leituras e diferença entre HIT e MISS.
10	Balanceamento	v14. Distribuição e exclusão de instância sem resposta.
11	Consistência forte e eventual	v17. Compra usa fonte da verdade; catálogo aceita propagação.
12	Timeout, retry e circuit breaker	Descritos nas dependências; não apresentados como serviços novos.
13	Cliente, DNS e CDN	v13. Relações DNS/HTTPS distintas; 90% conteúdo estável preservado sem converter em HIT.
14	Load Balancer e TLS	v14. Terminação e nova sessão TLS explicam os dois trechos HTTPS.
15	Múltiplas instâncias e autorização	v15. 3 caixas explícitas no estágio; validação antes do domínio.

Slide / página	Conteúdo original	Representação no Build Arch
16	Cache e proteção dos dados	v16. Pagamento/documentos fora do cache; TTL pessoal curto.
17	Writer e réplicas	v17. Duas réplicas separadas; repouso criptografado e menor privilégio.
18	Assíncrono, observabilidade e multi-região	v18. 50 mil mensagens/h, 3 > 20 workers, aviso 3 min, 40/220 ms preservados como exemplos do slide.
19	Arquitetura de referência	v19. Todas as funções da figura representadas; duas réplicas e tracing retomam os slides 17-18.
20	Deploy gradual e rollback	v19. Fração do tráfego/região; métricas orientam retorno.
21	Pico além do planejado	v19. Rate limiting, sala de espera, modo degradado, teto e alarme.
22	Carga ao vivo	v19. Mapa mostra as peças; Labs demonstram causalidade com controles iguais.
23	Gargalo orienta investimento	v19. Comparação dos Labs 01/02/03 preservada.
24	Compute, storage, egress e CDN	v19. AWS, GCP, Azure e Alibaba no guia; preços fixos não adicionados.
25	Evolução, segurança e caminho de volta	v19. Histórico e controles demonstram fechamento sem mudar as fontes.

Critério para as conexões

DNS e autenticação representam resolução/configuração, não proxies HTTP em série. Orquestração, autoscaler, telemetria e CI/CD são relações de controle/operação. A/B são destinos alternativos de leitura. Replicação regional não declara active-active. Checkout > fila representa trabalho pós-compra; o mecanismo confiável de publicação fica no aprofundamento.

Detalhes de implementação mantidos como apoio

A v9 conserva outbox/relay/DLQ, provedor de pagamento e metas de recuperação propostas antes desta revisão. O schema de oito tabelas, os manifests e as notas de idempotência continuam disponíveis. Esses detalhes não são atribuídos aos slides. 2.000 req/min, banco 3.000/20.000 e hipóteses de custo/capacidade são parâmetros dos Labs/modelo.

Três distinções para a explicação

O slide 14 menciona terminação TLS e HTTPS em todos os trechos: a entrada encerra uma sessão e abre outra protegida. O slide 18 permite baixa assíncrona, enquanto os slides 4/11/17 exigem estoque correto na compra: reserva antes de confirmar, baixa operacional depois. O slide 22 fala em P95: saídas heurísticas do Build Arch não são percentis medidos em produção. As fontes não foram reescritas.